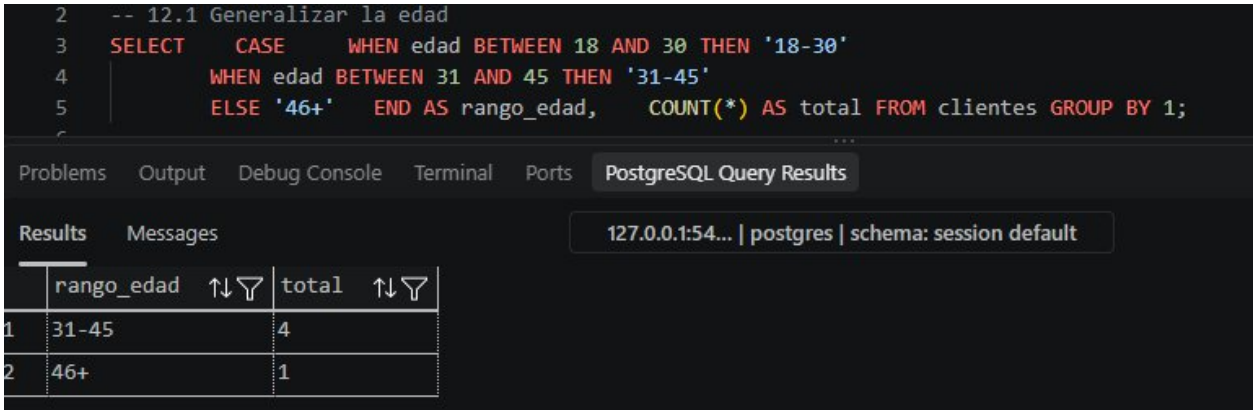
El área de dirección solicita información estadística.

No necesita conocer los clientes individualmente.

El objetivo es generar información agregada y reducir el riesgo de reidentificación.

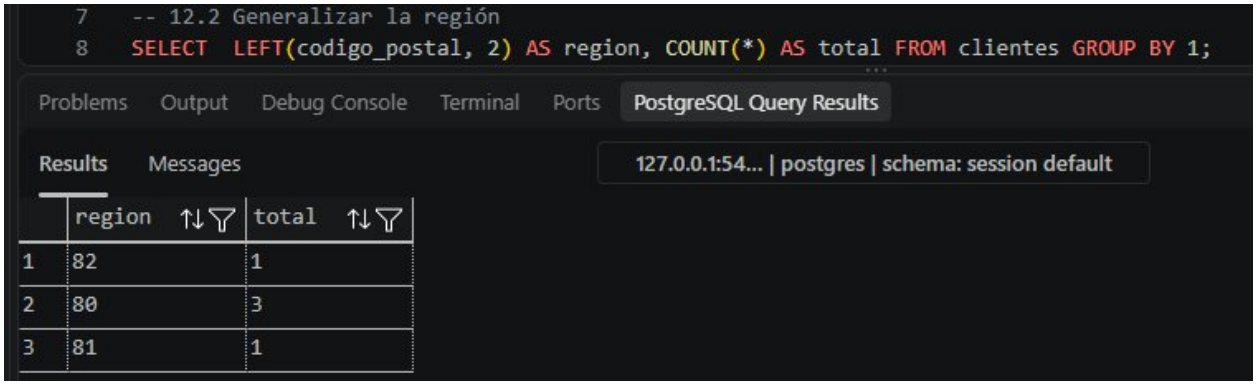
12.1 Generalizar la edad

SELECT CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
WHEN edad BETWEEN 31 AND 45 THEN '31-45'
ELSE '46+' END AS rango_edad, COUNT(*) AS total FROM clientes GROUP BY 1;



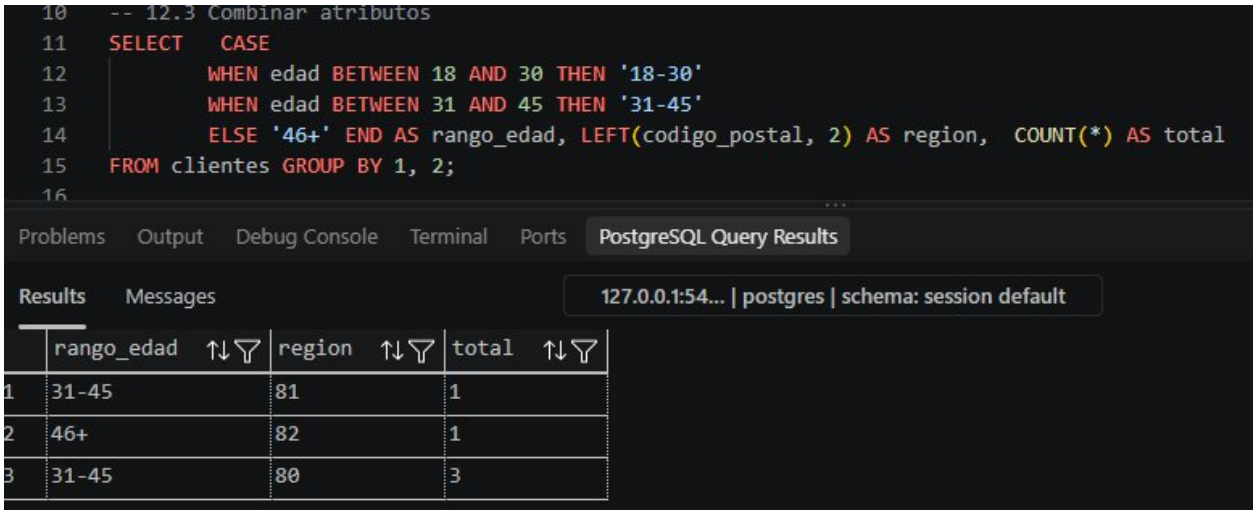
12.2 Generalizar la región

SELECT LEFT(codigo_postal, 2) AS region, COUNT(*) AS total FROM clientes GROUP BY 1;



12.3 Combinar atributos

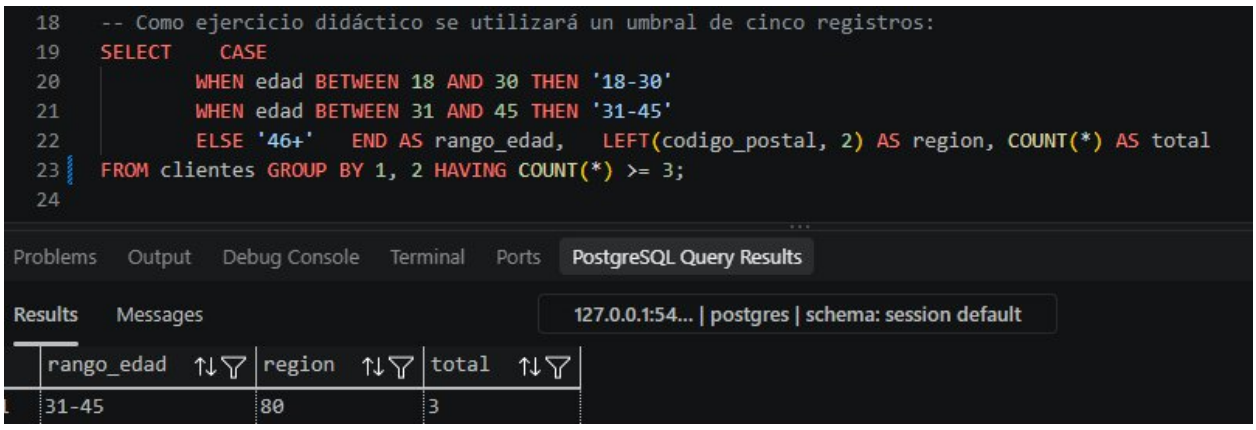
```
SELECT   CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+' END AS rango_edad, LEFT(codigo_postal, 2) AS region,  COUNT(*) AS total
FROM clientes GROUP BY 1, 2;
```



12.4 Suprimir grupos pequeños

Como ejercicio didáctico se utilizará un umbral de cinco registros:

```
SELECT    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+'   END AS rango_edad,   LEFT(codigo_postal, 2) AS region, COUNT(*) AS total
FROM clientes GROUP BY 1, 2 HAVING COUNT(*) >= 5;
```



El atributo cambio a 3 para permitir la visualización de resultados en la practica. La muestra de datos es pequeña y con el umbral original de 5, todos los grupos resultaban eliminados. Con este parametro se despliega el grupo correspondiente al

rango de edad 31-45 y region 80 con un conteo de 3 personas, esta seria la regla de supresión que busca mitigar el riesgo de reidentificación en grupos reducidos (donde un atacante con información externa previa podría deducir fácilmente a qué persona corresponde un registro). Al bajar el umbral a 3, este riesgo aumenta.

13. Actividad 6 — Análisis del riesgo de reidentificación

Analizar el resultado obtenido en la actividad anterior.
Responder:

1. **¿Qué identificadores directos fueron eliminados?**
   Se eliminaron el nombre, correo, telefono, rfc y el id original de la tabla de clientes.
2. **¿Qué cuasi-identificadores permanecen?**
   Permanecen la edad (transformada en rango_edad) y el codigo_postal (transformado a los 2 primeros dígitos como region).
3. **¿Qué combinaciones de atributos podrían reducir el anonimato?**
   La combinación simultánea de rango_edad y region, especialmente si se cruza o contrasta con bases de datos públicas o fuentes externas.
4. **¿Qué sucede cuando un grupo contiene pocos registros?**
   Aumenta exponencialmente el riesgo de reidentificación, ya que un atacante con conocimientos previos puede aislar y deducir la identidad del individuo.
5. **¿Qué atributos deberían generalizarse?**
   Aquellos datos con alto nivel de detalle que actúan como cuasi-identificadores, tales como la edad exacta, el codigo_postal completo y fechas específicas (fecha_alta).
6. **¿Qué información debería suprimirse?**
   Aquellas agrupaciones o datos atípicos que no cumplan con el umbral mínimo de registros establecido (por ejemplo, grupos donde COUNT(*) < 5).
7. **¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué?**
   No, porque el anonimato absoluto no existe. Reducir el detalle o aplicar un filtro de agregación no garantiza por sí solo la anonimización si la información puede combinarse con otras fuentes externas.